

HW4 Transfer Learning Report

1.1 Task A: Model Selection

Two models : VGG、ResNet

➤ vgg13 model :

VGG13 是 VGGNet 系列之一，它由牛津大學視覺幾何組 (Visual Geometry Group, VGG) 提出，其使用大量的 3x3 filter 堆疊，代替較大的 filter，來加深網絡的深度。架構由一系列的卷積層 (Conv2d)、activation function (ReLU) 和 pooling layer (MaxPool2d) 組成。總共 10 個卷積層，全部使用 3x3 filter，每個卷積層後都跟著使用 ReLU，確保非線性。每當 neuron 數量增加一倍時，使用 max pooling 來減小輸出 features 尺寸。最後使用 classifier layer，先進行 average pooling，接著使用一系列的線性 fully connect layer，ReLU 以及 dropout 輸出結果。

VGG13 包含 10 個 Conv 層和 3 個 FC 層，其深度能夠捕捉到更複雜的特徵，透過其結構深度和小 filter 的堆疊，可以捕捉到更多的圖像細節和特徵，使得在大規模圖像分類的任務中表現優異。除此之外，在卷積層之間使用 max pooling 來減小 data 的 size 大小，從而減少計算量和參數量。

➤ resnet18 model :


ResNet18 使用了 18 層的 CNN，在輸入層參數 Conv2d(3, 64, kernel_size=(7, 7), stride=(2, 2), padding=(3, 3), bias=False)，接著使用四個 residual blocks，每個 residual block 中包含兩個 basic blocks，每個 basic block 又包含兩層卷積、兩層 batchNorm，以及 activation function(ReLU)。另外，在第二、三、四層 residual block 的第一個 basic block 中還使用 downsample，確保了跳躍連接中輸入和輸出的 size 一致性，並幫助模型提取更高層次的特徵。最後使用 average pooling，再連接 fully connect layer 輸出結果。

ResNet18 在圖像辨識的任務上表現優異，能有效學習豐富特徵。residual block 包括了 skip connections，透過 skip connections 使得原始輸入能加到後層的輸出上，有助於減少 vanish gradient 問題。根據論文《Deep Residual Learning for Image Recognition》[1]的實驗結果，ResNet18 在 ImageNet 上的 Top-1 精度通常在 69-70% 之間，Top-5 精度則在 89-90% 之間，代表模型在大多數情況下能準確識別圖像中的對象。此外，ResNet18 的深度適中，相比於更深的網絡（如 ResNet50、ResNet101），其計算時間相對較短，適合在 data

source 有限的情況下採用。


1.2 Task B: Fine-tuning the ConvNet

➤ **VGG13 fine-tuning 結果如下：**



Test Accuracy: 80.52%
Test Loss: 0.4866

➤ **ResNet18 fine-tuning 結果如下：**



Test Accuracy: 84.64%
Test Loss: 0.3994


VGG13 層數較深，參數也多，Conv 層和 FC 層交替堆疊構成 model，當中皆使用 3x3 的 filters，其優點在於架構單純和一致性，但可能會因深度較深的情況下，遇到 gradient

vanish 的問題。從 well-tuning 結果觀察 train loss 穩定下降，train accuracy 穩定上升；但在 validation loss 偏大的情況下，validation accuracy 也變得非常不穩定得波動，因此在 test accuracy 表現也比 ResNet18 差了一些。若要改進 model 表現可考慮增加使用 regularization，調整 hyperparameters。此外，validation accuracy 的波動可能與驗證集的大小或分佈有關，若在調整過 hyperparameters 後也無法改進 model 效能，可考慮修改 validation data。

而 ResNet18 引入了 skip connections，使得訓練更深層的 NN 變得更容易進行，ResNet18 通過 residual 來避免產生 gradient vanish，能夠在相對較少的參數情況下，獲得更好的性能表現。從 well-tuning 結果觀察，train loss 能訓練至接近 0，train accuracy 則能接近 100%，然而 validation loss 持續下降至 0.4 左右就停滯無法再降低，validation accuracy 同樣也在上升至 85% 左右就停滯無法再進步；當訓練集損失和準確率接近 0 和 100% 時，而驗證損失和準確率開始波動，推測應為過擬合現象，應透過調整 hyperparameters 來改善效能表現。最後比較在 test accuracy 表現比 VGG13 更理想些。

1.3 Task C: ConvNet as Fixed Feature Extractor

➤ VGG13：




VGG13 的 Conv 層可以視為特徵提取器，在 pre-train model 中，這些 Conv 層經過大量的圖像數據訓練，已學習到了一組合適的 features，涵蓋邊緣、形狀、紋理等低層和中層特徵。透過凍結這些 Conv 層，維持這些提取特徵，不再對它們進行調整。

FC 層將從 Conv 層提取到的特徵映射到具體的新任務空間上。在 model 中只允許最後幾個 FC 層的參數進行更新，使模型可以學習與新任務相關的模式，並減少過度擬合的風險，因為 Conv 層的 parameters 已經固定。

除 FC 層之外，還兼用 ReLU activation function 和 dropout，確保了計算上的非線性，促使 NN 能提取更複雜的特徵，同時降低過擬合發生的可能，並且減少 gradient vanish 的問題，整體提升 model 學習能力與訓練速度，還提高了對新任務的適應性。

從上圖執行結果來看，training set 的表現變化起伏不定，而 validation set 則完全持平不便，結果並不理想。需針對 learning rate 或是訓練 epochs 數等等的 hyperparameters 做出修正已改進 model 穩定性。

➤ ResNet18：



ResNet18 model 中存在 batch normalization 和 residual connections 能有效地穩定梯度、促進深層特徵學習，即使在特徵提取模式下，這些層也能增強 model 的 generalization 能力。

當凍結住 ResNet18 model 前部分所有 residual blocks 後，只允許最後的 FC 層參數更新，將先前 Conv 層提取的特徵映射到新任務的輸出空間。這樣的設計使模型能夠針對新任務的特徵進行調整，而不影響前面已學到的通用特徵，有助於快速適應新的數據集和目標類別。

從上圖的訓練結果來看，train loss 穩定下降，且 accuracy 逐步上升，說明 model 確實在新任務上有學習效果。不過，validation set 的 accuracy 在訓練過程中保持不變，可能與 data set 或的 feature extractor(FC 層)表現能力相關，可採取 data augmentation 增強數據集，或者調整 hyperparameters 來改進。

1.4 Task D: Comparison and Analysis

fine-tuned 的過程 model 可以透過一系列的 Conv 層設計對 new task 做學習，分析提取新特徵，以增進最後性能的表現；而 fixed feature extractor 則凍結住 Conv 層執行新的學習，保留原先所得的特徵，再對 new task 做分析表現。從實驗結果明顯可知 fine-tuned 能在 new task 中有較強適應性，能更快速學習並反映在訓練結果表現上。

1.5 Task E: Test Dataset Analysis

在訓練 model 時遇到瓶頸，即使調整 hyperparameters（如 learning rate、weight decay、epochs 等）和 parameters（如 dropout、activation function 等）仍無法進一步提升 test set 的損耗和準確性，推測可能有以下幾個原因和現象導致：

- (a) Model Overfitting：model 在 train set 表現優異，但在 test set 上表現不佳。過擬合 model 過於專注於訓練數據的細節和 noise，缺乏 generalization 能力。此情形可使用 regularization（如 L1、L2）、data augmentation 等。
- (b) Model Underfitting：model 無法在 train set 達到足夠低的損耗。可能因 model 架構設計過於簡單，無法捕捉 data set 中較複雜的特徵。解決方案包括增加 model 的複雜度（如增加層數、neuron 數量）、選擇更強大的 model 架構等。
- (c) Insufficient or Imbalanced Training Data：訓練數據量不足或數據分布不均衡會導致 model 無法學到充分的 features。改進方式包括收集更多的 training data set、使用 data augmentation、調整數據平衡等。
- (d) Vanishing or Exploding Gradients：neural network 中特別容易發生 gradient vanishing or exploding，導致 model 無法有效訓練。可嘗試使用適當的 weight initialization method 等。

引用文獻：

[1] He, K., Zhang, X., Ren, S., & Sun, J., "Deep Residual Learning for Image Recognition," IEEE conference on computer vision and pattern recognition (CVPR), 2016.